



Práctica: Manipulación de Datos Médicos con dplyr



Objetivo de la práctica

En esta actividad aprenderás a manipular datos biomédicos utilizando funciones del paquete dplyr, parte del ecosistema tidyverse en R.



Competencias que desarrollarás:

- Filtrar datos clínicos
- Ordenar observaciones
- Seleccionar columnas
- Crear nuevas variables
- Calcular estadísticas resumen
- Agrupar información clínica
- Utilizar el operador pipe %>%



Base de datos utilizada

Trabajaremos con el dataset PimaIndiansDiabetes2, el cual contiene información clínica utilizada para estudiar diabetes tipo 2.

- pregnant → Número de embarazos
- glucose → Concentración de glucosa
- pressure → Presión arterial
- triceps → Grosor del tríceps
- insulin → Nivel de insulina
- mass → Índice de masa corporal (IMC)
- pedigree → Historial familiar de diabetes
- age → Edad
- diabetes → Diagnóstico (pos/neg)



Paquetes necesarios

```
# install.packages("tidyverse")
```

```
# install.packages("mlbench")
```

```
library(tidyverse)
```

```
library(dplyr)
```

```
library(mlbench)
```

```
data("PimaIndiansDiabetes2")
```

Ejercicios

Ejercicio 1

Visualiza las primeras 6 filas del dataset.

💡 Pista: utiliza la función `head()`.

Ejercicio 2

Muestra los nombres de todas las variables disponibles.

💡 Pista: utiliza `names()`.

Ejercicio 3

Identifica cuántas filas y columnas tiene el dataset.

💡 Pista: utiliza `dim()`.

Ejercicio 4

Filtra únicamente los pacientes mayores de 50 años.

Guarda el resultado en un objeto llamado `pacientes_mayores`.

💡 Pista: utiliza `filter()`.

Ejercicio 5

Filtra los pacientes con glucosa mayor a 140.

Muestra las primeras filas del resultado.

Ejercicio 6

Filtra los pacientes cuya edad se encuentre entre 30 y 40 años.

💡 Debes utilizar `between()`.

Ejercicio 7

Selecciona únicamente los pacientes con diagnóstico positivo de diabetes.

💡 Recuerda que la variable diabetes contiene 'pos' y 'neg'.

Ejercicio 8

Ordena el dataset por glucosa de menor a mayor.

💡 Usa `arrange()`.

Ejercicio 9

Ordena los pacientes por IMC (mass) de mayor a menor.

💡 Usa `desc()` dentro de `arrange()`.

Ejercicio 10

Ordena el dataset primero por edad y después por glucosa.

Ejercicio 11

Selecciona únicamente las columnas:
glucose, pressure, mass y diabetes.

💡 Usa `select()`.

Ejercicio 12

Selecciona solamente las variables numéricas del dataset.

💡 Usa `where(is.numeric)`.

Ejercicio 13

Selecciona únicamente las variables NO numéricas.

Ejercicio 14

Crea una nueva columna llamada `edad_meses`.
La nueva variable debe convertir la edad de años a meses.

💡 Usa `mutate()`.

Ejercicio 15


Crea una nueva columna llamada `glucosa_categoria`.

Clasifica a los pacientes de la siguiente manera:

- 'Normal' → glucosa menor a 100
- 'Prediabetes' → glucosa entre 100 y 125
- 'Diabetes' → glucosa mayor o igual a 126

💡 Utiliza `case_when()`.

Ya que no lo vimos en la clase pero me parece muy útil, les dejo la explicación



Esta es la forma en que funciona

```

27 {r}
28 {r}
29 case_when(
30   condición ~ resultado,
31   condición ~ resultado
32 )
33

```

⚙ Ejercicio 16

Crea una nueva columna llamada IMC_redondeado.

Redondea la variable mass utilizando round() que te ayuda a redondear tus datos.

📊 Ejercicio 17

Calcula el promedio de glucosa.

💡 Usa summarize() y recuerda incluir na.rm = TRUE.

📊 Ejercicio 18

Calcula las siguientes estadísticas:

- Promedio de glucosa
- Promedio de edad
- Promedio de IMC

📊 Ejercicio 19

Calcula la glucosa máxima y mínima del dataset.

💡 Usa max() y min().

👤 Ejercicio 20


Calcula el promedio de glucosa agrupando por diabetes.

📌 Instrucciones:

- Usa la función `group_by()` para agrupar los datos utilizando la variable diabetes.

`group_by()` es una de las funciones más importantes de tidyverse y específicamente de dplyr. Sirve para decirle a R:


“Quiero analizar mis datos por grupos”.



Por sí sola, `group_by()` **no calcula nada**.

Lo que hace es organizar temporalmente los datos en categorías para que otras funciones trabajen por grupo.

Normalmente `group_by()` se combina con `summarise()` para obtener estadísticas por grupo.



- Después utiliza `summarize()` para calcular el promedio de glucosa.
- La nueva columna debe llamarse `promedio_glucosa`.
- Recuerda incluir `na.rm = TRUE` dentro de `mean()` para ignorar valores faltantes.

- Guarda el resultado en un objeto llamado `resumen_glucosa`.

💡 Pista:

Primero agrupas los datos y después haces el resumen estadístico.

Preguntas de reflexión

- ¿Qué función te pareció más útil y por qué?
- ¿Por qué es importante trabajar con datos tidy?
- ¿Qué ventajas tiene utilizar el operador `%>%`?

✨ Entrega del reporte

Crea tu reporte en **R Markdown** y entrégalo en formato **PDF o HTML**. Además, debes adjuntar el archivo fuente con extensión `.Rmd`. 

Tu documento debe estar bien organizado y aprovechar las herramientas vistas en clase de **R Markdown**, incluyendo:

-  Títulos y subtítulos
-  Tabla de contenidos
-  Secciones claramente identificadas
-  Código y resultados bien presentados
-  Un formato limpio y fácil de leer

✅ Se evaluará tanto el análisis realizado como la **presentación, organización y claridad** del reporte.

✨ ¡Fin de la práctica! ✨